

Отчёт по AI/ML-проекту: прогнозирование цены золота на 30 торговых дней

Юсупов Данил, Панчук Павел, Маликов Евгений | курс «Технологии искусственного интеллекта и продвинутой аналитики»

1. Введение

Цель проекта - построить воспроизводимый ML-пайплайн для прогноза цены закрытия золота. Бизнес-смысл задачи связан с поддержкой аналитики финансовых рынков: золото используется как защитный актив, поэтому прогноз помогает инвесторам, банкам и риск-менеджерам оценивать рыночный риск, планировать хеджирование и формировать сценарии.

ML-формулировка: регрессия временного ряда. Целевая переменная - цена закрытия золота на следующий торговый день, а прогноз на 30 дней строится итеративно. Основная метрика - MAE, потому что она показывает среднюю ошибку в долларах США и легко интерпретируется в бизнес-контексте. Дополнительно использовались RMSE, MAPE и R^2 .

2. Данные

Данные загружены через yfinance из Yahoo Finance. Фактический период наблюдений: 2010-01-04 - 2026-06-03. Итоговый набор содержит 4133 строки и 6 базовых рыночных признаков.

Тикер	Признак	Смысл
GC=F	gold_close	цена закрытия фьючерса на золото
DX-Y.NYB	usd_index_close	индекс доллара США
^GSPC	sp500_close	индекс S&P 500
CL=F	wti_oil_close	цена нефти WTI
SI=F	silver_close	цена серебра
^TNX	us_10y_yield_close	доходность 10-летних облигаций США

3. Разведочный анализ данных

Цена золота за рассматриваемый период существенно выросла и к 2026 году находится в новом высоком ценовом диапазоне. Это важно для выбора модели: алгоритмы, которые плохо экстраполируют за пределы обучающего диапазона, могут давать крупные ошибки на тестовом периоде.



Рисунок 1. Динамика цены золота за период наблюдений.

Распределение дневной доходности сконцентрировано около нуля и имеет тяжелые хвосты. Это типично для финансовых временных рядов: в большинстве дней изменение небольшое, но отдельные периоды сопровождаются резкими движениями.




Рисунок 2. Распределение дневной доходности золота.

Корреляционный анализ показывает связь золота с внешними рынками. Особенно важны доллар США и серебро: это соответствует рыночной логике, так как золото чувствительно к валютному фактору и динамике драгоценных металлов.




Рисунок 3. Корреляционная матрица рыночных признаков.

- Пропуски после объединения временных рядов обработаны forward fill.
- Агрессивная фильтрация выбросов не применялась: резкие движения цены являются частью рыночной динамики.
- Случайное перемешивание данных не использовалось, чтобы избежать утечки будущей информации.

4. Подготовка данных и Feature Engineering

Группа признаков	Примеры	Зачем нужны
Лаги	gold_lag_1, gold_lag_7, gold_lag_30	учитывают инерцию временного ряда
Скользящие средние	sma_7, sma_14, sma_30, sma_90	показывают локальный тренд
Волатильность	volatility_7, volatility_14, volatility_30	отражает уровень рыночной неопределенности
Доходности	return_1d, return_7d, return_30d	нормируют изменения цены
Календарные признаки	день недели, месяц, квартал, год	фиксируют сезонные паттерны
Внешние рынки	USD, S&P 500, нефть, серебро, доходность облигаций	добавляют макро- и рыночный контекст

Разделение выполнено хронологически: 70% train, 15% validation, 15% test. Scaler обучался только на train внутри Pipeline, а validation и test трансформировались уже обученным преобразователем.

5. Моделирование и сравнение моделей

В качестве baseline использованы naïve forecast и скользящие средние MA(7), MA(14), MA(30). Naïve baseline на test дал MAE 33.72 USD и MAPE 0.96%, поэтому он является сильным ориентиром для one-step прогноза.

Модель	MAE valid	RMSE valid	MAPE valid	MAE test	RMSE test	MAPE test
Linear Regression	12.94	17.20	0.70%	34.29	55.51	0.97%
Ridge Regression	12.95	17.20	0.70%	34.73	55.82	0.99%
Gradient Boosting	19.44	28.28	1.02%	1212.05	1522.16	32.43%
Random Forest	21.16	30.82	1.11%	1202.78	1512.68	32.16%
MLPRegressor	109.90	131.51	5.86%	821.23	1066.51	21.90%




Рисунок 4. Сравнение моделей по качеству на validation и test.

Лучшей ML-моделью по validation MAE стала Linear Regression. На test она получила MAE 34.29 USD и MAPE 0.97%. Сложные нелинейные модели показали слабую переносимость на новый ценовой диапазон: деревья и бустинг ограниченно экстраполируют значения за пределы диапазона обучения.

6. Интерпретация итоговой модели

Наиболее важный фактор - текущая цена золота. Среди внешних факторов выделяются индекс доллара, S&P 500, серебро и лаги этих показателей. Это согласуется с экономической логикой: краткосрочный прогноз золота во многом определяется инерцией цены и состоянием смежных рынков.

Признак	Важность
gold_close	241.998
usd_index_close_lag_1	82.211
usd_index_close	81.632
sp500_close	45.786
sp500_close_lag_1	45.415
gold_lag_7	23.618
silver_close	20.882
silver_close_lag_1	20.756
sma_30	13.545
wti_oil_close_lag_1	11.420




Рисунок 5. Топ признаков итоговой модели.

Анализ ошибок показывает, что модель хуже работает на резких движениях цены. Это ожидаемо для подхода без новостного и макроэкономического контекста: внезапные рыночные события трудно восстановить только по историческим ценам и лагам.




Рисунок 6. Фактические и предсказанные значения на тестовом периоде.

7. Прогноз на 30 дней и ограничения

Итеративный прогноз на 30 торговых дней предполагает умеренное продолжение роста: первый прогнозный день - 2026-06-04, цена 4437.90 USD; последний прогнозный день - 2026-07-15, цена 4515.62 USD. Для будущих значений внешних факторов использован подход last observation carried forward, так как реальные будущие значения рынков неизвестны.



Рисунок 7. Прогноз цены золота на 30 торговых дней.

8. MLOps, воспроизводимость и выводы

Сохранены артефакты `best_model.pkl`, `feature_columns.pkl`, `feature_pipeline.pkl`, `scaler.pkl`, `metadata.json` и `forecast_30_days.csv`. В ноутбуке есть пример инференса: загрузка модели через `joblib`, подготовка признаков и получение прогноза. Для эксплуатации требуется мониторинг data drift по цене, доходностям, волатильности и внешним факторам.

Главный результат проекта: для краткосрочного прогноза золота naive baseline оказался очень сильным и немного превзошел Linear Regression на test. Это важный практический вывод: в финансовых временных рядах сложная модель должна доказывать ценность относительно простого baseline. Проект демонстрирует полный цикл ML-задачи: данные, EDA, feature engineering, baseline, модели, интерпретацию, прогноз и MLOps.

- Ограничения: накопление ошибки при итеративном прогнозе, отсутствие прогноза будущих внешних факторов, отсутствие новостного и sentiment-контекста.
- Развитие: добавить макроиндикаторы и ставки ФРС, реализовать rolling backtesting, протестировать ARIMA/Prophet/LSTM/TFT, настроить мониторинг drift и регулярное переобучение.